

Mô Hình ARIMA Trong Bài Toán Dự Báo Chuỗi Thời Gian


Nguyễn Thế Hào

Hồ Đăng Mạnh

Đình Quang Vinh

I. Giới thiệu

Bài toán dự báo chuỗi thời gian từ lâu đã là một lĩnh vực nghiên cứu nền tảng, có giá trị ứng dụng cao trong kinh tế, sản xuất công nghiệp và môi trường. Điểm khác biệt cốt lõi của chuỗi thời gian so với các dạng dữ liệu khác nằm ở cấu trúc thứ tự: trạng thái của một quan sát luôn chịu tác động trực tiếp từ các biến cố xảy ra trước đó. Vì vậy, thách thức chính của bài toán không chỉ là phân tích thống kê thông thường, mà là trích xuất hiệu quả các quy luật biến động theo thời gian. Đặc điểm này đòi hỏi việc phát triển các mô hình dự báo chuyên biệt, có khả năng diễn dịch chuỗi quan sát trong quá khứ thành những ước lượng đáng tin cậy cho tương lai.



Hình 1: Minh họa cấu trúc hệ thống và luồng xử lý của mô hình ARIMA trong dự báo chuỗi thời gian

Trong phân tích chuỗi thời gian, một mục tiêu quan trọng là mô tả mối quan hệ giữa giá trị hiện tại và các thông tin trong quá khứ. Hai mô hình nền tảng thường được sử dụng là AR (*AutoRegressive*) và MA (*Moving Average*). Tuy nhiên, nhiều chuỗi dữ liệu thực tế không dừng do có xu hướng dài hạn, biến động thay đổi theo thời gian hoặc chịu tác động của các cú sốc. Vì vậy, việc áp dụng trực tiếp AR hoặc MA thường chưa phù hợp.

Mô hình ARIMA (*AutoRegressive Integrated Moving Average*) kết hợp hai thành phần AR và MA, đồng thời bổ sung thành phần sai phân (*Integrated*) để xử lý tính không dừng của dữ liệu [1, 2]. Nhờ đó, chuỗi ban đầu có thể được chuyển về dạng ổn định hơn trước khi xây dựng mô hình dự báo. ARIMA cũng gắn với quy trình Box–Jenkins, bao gồm nhận diện mô hình, ước lượng tham số và kiểm định chẩn đoán phần dư.

Nội dung bài viết tập trung vào các phần chính sau:

- Giới thiệu các khái niệm nền tảng của chuỗi thời gian, tính dừng và phép sai phân.
- Trình bày mô hình ARIMA thông qua ba thành phần AR, I và MA; đồng thời làm rõ vai trò của ACF/PACF trong lựa chọn tham số p , d , q .
- Mô tả quy trình xây dựng mô hình ARIMA, bao gồm lựa chọn tham số, ước lượng mô hình, chọn mô hình bằng AIC, chẩn đoán phần dư, dự báo và đánh giá sai số.
- Minh họa quy trình bằng Python trên tập dữ liệu Sunspots và giới thiệu web demo hỗ trợ thực hành trực quan.

Mục lục

I.	Giới thiệu	1
II.	Cơ sở lý thuyết	4
II.1.	Chuỗi thời gian và bài toán dự báo	4
II.2.	Các thành phần cơ bản của chuỗi thời gian	4
II.3.	Mô hình ARIMA	5
II.4.	Tính dừng và phép sai phân	6
II.5.	Thành phần AR: ảnh hưởng từ giá trị quá khứ	9
II.6.	Thành phần MA: ảnh hưởng từ sai số quá khứ	10
II.7.	ACF và PACF trong lựa chọn tham số	11
III.	Quy trình xây dựng mô hình ARIMA	12
III.1.	Sai phân và lựa chọn tham số d	13
III.2.	Nhận diện p và q bằng ACF/PACF	14
III.3.	Đặt mô hình ứng viên và ước lượng tham số	16
III.4.	Chọn mô hình bằng AIC	17
III.5.	Chẩn đoán phần dư	19
III.6.	Dự báo giá trị tương lai	20
III.7.	Đánh giá sai số dự báo	21
III.8.	Giới hạn của ARIMA và hướng mở rộng	22
IV.	Ví dụ minh họa với Python	23
IV.1.	Cài đặt và import thư viện	23
IV.2.	Chuẩn bị và trực quan hóa dữ liệu	23
IV.3.	Kiểm tra tính dừng và chọn d	25
IV.4.	Nhận diện p, q bằng ACF/PACF	26
IV.5.	Lựa chọn mô hình bằng AIC	28
IV.6.	Huấn luyện mô hình ARIMA được chọn	29
IV.7.	Chẩn đoán phần dư	29
IV.8.	Dự báo trên tập kiểm tra và so sánh mô hình	31
V.	Thực hành ARIMA trên Web Demo	34


II. Cơ sở lý thuyết

II.1. Chuỗi thời gian và bài toán dự báo

Chuỗi thời gian là gì?

Chuỗi thời gian (*Time Series*) là tập hợp các quan sát được ghi nhận theo thứ tự thời gian, thường tại các khoảng cách đều nhau như từng giờ, từng ngày, từng tháng hoặc từng năm.

Điểm quan trọng nhất của chuỗi thời gian là **thứ tự quan sát**. Giá trị tại thời điểm hiện tại thường chịu ảnh hưởng từ các giá trị trong quá khứ, vì vậy ta không thể xáo trộn dữ liệu như trong nhiều bài toán học máy thông thường. Mục tiêu của dự báo chuỗi thời gian là khai thác thông tin trong quá khứ để ước lượng giá trị tương lai.




Hình 2: Minh họa cấu trúc cơ bản của dữ liệu chuỗi thời gian

Trong Hình 2, trục hoành biểu diễn thời gian t , trục tung biểu diễn giá trị quan sát Y_t . Mỗi điểm dữ liệu là một giá trị được ghi nhận tại một thời điểm cụ thể. Đường nối các điểm giúp ta quan sát xu hướng, biến động và cấu trúc phụ thuộc theo thời gian của chuỗi.

II.2. Các thành phần cơ bản của chuỗi thời gian

Một chuỗi thời gian quan sát được thường là sự kết hợp của nhiều thành phần khác nhau. Việc nhận diện các thành phần này giúp ta hiểu đặc điểm dữ liệu trước khi xây dựng mô hình dự

báo.



Hình 3: Minh họa các thành phần cơ bản của chuỗi thời gian

Các thành phần thường gặp gồm:

- **Chuỗi quan sát** (*Observed Series*): dữ liệu thực tế được ghi nhận theo thời gian.
- **Xu hướng** (*Trend*): chuyển động dài hạn của chuỗi, ví dụ tăng dần hoặc giảm dần.
- **Mùa vụ** (*Seasonality*): dao động lặp lại theo chu kỳ cố định.
- **Nhiễu** (*Noise*): phần biến động ngẫu nhiên, khó dự báo và không có quy luật rõ ràng.

Với ARIMA cơ bản, yếu tố cần chú ý nhất là **xu hướng**. Nếu chuỗi có xu hướng rõ rệt, dữ liệu thường chưa dừng và cần được xử lý trước khi mô hình hóa.

II.3. Mô hình ARIMA

ARIMA là gì?


ARIMA (*AutoRegressive Integrated Moving Average*) là mô hình thống kê dùng để dự báo chuỗi thời gian đơn biến. Mô hình khai thác thông tin từ chính các giá trị quá khứ và sai số quá khứ của chuỗi.

Mô hình ARIMA được ký hiệu là:

$$ARIMA(p, d, q)$$

Trong đó:

- p : số độ trễ của giá trị quá khứ được dùng trong thành phần tự hồi quy AR .
- d : số lần sai phân cần thực hiện để đưa chuỗi về trạng thái dừng.
- q : số độ trễ của sai số quá khứ được dùng trong thành phần trung bình trượt MA .



Hình 4: Ba thành phần chính của mô hình ARIMA

Có thể hiểu ngắn gọn: thành phần AR học từ giá trị quá khứ, thành phần I làm chuỗi ổn định hơn bằng sai phân, còn thành phần MA điều chỉnh dự báo dựa trên sai số quá khứ.

II.4. Tính dừng và phép sai phân

Tính dừng là gì?

Một chuỗi thời gian được gọi là **dừng** khi các đặc trưng thống kê chính của nó không thay đổi theo thời gian. Trực quan hơn, chuỗi dừng thường dao động quanh một mức trung bình ổn định và không có xu hướng tăng hoặc giảm dài hạn.

Trong ARIMA, ta thường xét **tính dừng yếu**. Một chuỗi Y_t được xem là dừng yếu nếu thỏa mãn:

1. Kỳ vọng không đổi:


$$E(Y_t) = \mu$$

2. Phương sai không đổi và hữu hạn:

$$Var(Y_t) = \sigma^2 < \infty$$

3. Hiệp phương sai chỉ phụ thuộc vào độ trễ:

$$\text{Cov}(Y_t, Y_{t-k}) = \gamma_k$$



Hình 5: So sánh chuỗi dừng và các trường hợp không dừng

Hình 5 cho thấy chuỗi không dừng có thể vi phạm điều kiện về trung bình hoặc phương sai. Với ARIMA, chuỗi cần đạt trạng thái đủ dừng để mô hình học được cấu trúc phụ thuộc ổn định theo thời gian.

Cách xử lý phổ biến là **sai phân** (*differencing*), tức lấy hiệu giữa các quan sát liên tiếp. Sai phân bậc một được định nghĩa bởi:

$$\Delta Y_t = Y_t - Y_{t-1} \quad (1)$$


Nếu chuỗi vẫn chưa dừng, ta có thể lấy sai phân bậc hai:

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad (2)$$

Hay tương đương:

$$\Delta^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2} \quad (3)$$

Số lần sai phân chính là tham số d trong $ARIMA(p, d, q)$. Cụ thể, $d = 0$ nghĩa là chuỗi gốc đã đủ dừng, $d = 1$ nghĩa là dùng sai phân bậc một, và $d = 2$ nghĩa là dùng sai phân bậc hai.



Hình 6: Minh họa quá trình làm giảm xu hướng bằng sai phân

💡 Lưu ý về sai phân

Sai phân giúp làm chuỗi ổn định hơn, nhưng không nên sai phân quá nhiều lần. Nếu d quá nhỏ, chuỗi vẫn có thể chưa dừng. Nếu d quá lớn, mô hình có thể làm mất cấu trúc quan trọng của dữ liệu và làm giảm chất lượng dự báo.

II.5. Thành phần AR: ảnh hưởng từ giá trị quá khứ


Thành phần **AR** (*AutoRegressive*) giả định rằng giá trị hiện tại có thể được giải thích bằng các giá trị quá khứ của chính chuỗi đó. Mô hình $AR(p)$ có dạng:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \quad (4)$$

Trong đó:

- Y_t : giá trị tại thời điểm hiện tại.
- $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$: các giá trị quá khứ.
- $\phi_1, \phi_2, \dots, \phi_p$: hệ số tự hồi quy.
- c : hằng số.
- ε_t : nhiễu ngẫu nhiên tại thời điểm t .

Tham số p cho biết mô hình nhìn lại bao nhiêu bước thời gian. Ví dụ, $AR(1)$ dùng một giá trị quá khứ Y_{t-1} , còn $AR(2)$ dùng hai giá trị quá khứ Y_{t-1} và Y_{t-2} .



$$\hat{Y}_t = 10 \text{ (Hằng số)} + 0.5 \times 100 \text{ (Ký ức gần)} + 0.3 \times 80 \text{ (Ký ức xa)} = 84$$

Hình 7: Minh họa quá trình tính toán của mô hình $AR(2)$

Trong Hình 7, giá trị hiện tại được tính từ hai giá trị quá khứ gần nhất sau khi nhân với các hệ số tương ứng. Vì mô hình dùng hai độ trễ nên đây là mô hình $AR(2)$.

II.6. Thành phần MA: ảnh hưởng từ sai số quá khứ


Thành phần **MA** (*Moving Average*) mô hình hóa ảnh hưởng của các sai số dự báo trong quá khứ. Mô hình $MA(q)$ có dạng:

$$Y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (5)$$

Trong đó:

- Y_t : giá trị tại thời điểm hiện tại.
- ε_t : sai số ngẫu nhiên hiện tại.
- $\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}$: sai số quá khứ.
- $\theta_1, \theta_2, \dots, \theta_q$: hệ số trung bình trượt.
- c : hằng số.

Tham số q cho biết mô hình sử dụng bao nhiêu sai số quá khứ để điều chỉnh giá trị hiện tại.



Hình 8: Minh họa quá trình tính toán của mô hình $MA(2)$

Trong Hình 8, mô hình $MA(2)$ dùng hai sai số quá khứ tại $t-1$ và $t-2$. Các sai số này được nhân với hệ số θ_1 và θ_2 , sau đó cộng vào mức nền để tạo ra giá trị dự báo.

II.7. ACF và PACF trong lựa chọn tham số

Sau khi chuỗi đã được làm dừng, ta thường dùng **ACF** và **PACF** để quan sát cấu trúc phụ thuộc theo thời gian. Hai công cụ này hỗ trợ lựa chọn tham số p và q cho mô hình ARIMA.

ACF là gì?

ACF (*Autocorrelation Function*) đo mức độ tương quan giữa giá trị hiện tại y_t và giá trị quá khứ y_{t-k} tại độ trễ k .

Hệ số tự tương quan mẫu tại lag k được tính bởi:

$$r_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} \quad (6)$$

Trong đó T là số quan sát và $\bar{y}$ là trung bình mẫu. Giá trị r_k nằm trong khoảng $[-1, 1]$. Giá trị càng xa 0 thì mức tương quan tại lag k càng rõ.

PACF là gì?

PACF (*Partial Autocorrelation Function*) đo mức tương quan trực tiếp giữa y_t và y_{t-k} , sau khi đã loại bỏ ảnh hưởng của các lag trung gian $1, 2, \dots, k-1$.

PACF tại lag k , ký hiệu α_k , có thể hiểu là hệ số cuối cùng trong mô hình $AR(k)$:

$$\alpha_k = \hat{\phi}_k \quad \text{trong mô hình } AR(k) \quad (7)$$

Vì vậy, ACF phản ánh tương quan tổng thể theo từng lag, còn PACF phản ánh phần ảnh hưởng trực tiếp của từng lag.


Vai trò của ACF và PACF trong ARIMA

- **PACF** thường được dùng để gợi ý tham số p của thành phần AR .
- **ACF** thường được dùng để gợi ý tham số q của thành phần MA .
- Tham số d được xác định thông qua số lần sai phân cần thiết để chuỗi đạt trạng thái đủ dừng.

Trong phần quy trình bên dưới, các công thức này sẽ được áp dụng trực tiếp trên một chuỗi dữ liệu nhỏ để minh họa cách nhận diện p và q .

III. Quy trình xây dựng mô hình ARIMA

Sau khi đã hiểu ý nghĩa của ba tham số p, d, q , ta cần nắm cách áp dụng ARIMA trên một chuỗi dữ liệu cụ thể. Phần này trình bày quy trình theo hướng: công thức được giới thiệu trước, sau đó áp dụng trực tiếp lên một ví dụ nhỏ để thấy dữ liệu thay đổi qua từng bước.



Hình 9: Quy trình tổng quát xây dựng mô hình ARIMA

Hình 9 mô tả quy trình xây dựng mô hình ARIMA từ dữ liệu ban đầu đến kết quả dự báo. Trước hết, ta quan sát chuỗi, kiểm tra tính dừng và dùng sai phân nếu cần để xác định tham số d . Sau đó, ACF/PACF được dùng để gợi ý p và q . Từ các tham số này, ta xây dựng các mô hình ứng viên, ước lượng tham số và chọn mô hình phù hợp bằng AIC. Mô hình được chọn tiếp tục được kiểm tra thông qua phần dư trước khi dùng để dự báo. Cuối cùng, kết quả dự báo được so sánh với dữ liệu kiểm tra bằng các thước đo như MAE, RMSE hoặc MAPE.

Để minh họa rõ cách dữ liệu đi qua từng bước trong quy trình trên, ta xét một chuỗi thời gian nhỏ gồm 8 quan sát:

$$y = [10, 12, 14, 15, 17, 19, 20, 22].$$

Chuỗi được chia thành tập huấn luyện và tập kiểm tra như sau:

$$y_{\text{train}} = [10, 12, 14, 15, 17, 19],$$

$$y_{\text{test}} = [20, 22].$$

Trong đó, tập huấn luyện được dùng để xây dựng mô hình, còn tập kiểm tra được dùng để đánh giá khả năng dự báo.

Thời điểm	1	2	3	4	5	6	7	8
Giá trị y_t	10	12	14	15	17	19	20	22
Vai trò	Train	Train	Train	Train	Train	Train	Test	Test

Mục tiêu của ví dụ là dùng 6 giá trị đầu để xây dựng mô hình ARIMA, sau đó dự báo hai giá trị tiếp theo:

$$[10, 12, 14, 15, 17, 19] \longrightarrow [\hat{y}_7, \hat{y}_8].$$

III.1. Sai phân và lựa chọn tham số d

Công thức sai phân bậc một đã được giới thiệu ở phần cơ sở lý thuyết:

$$\Delta y_t = y_t - y_{t-1}.$$

Công thức này chuyển chuỗi gốc y_t thành chuỗi biểu diễn mức thay đổi giữa hai thời điểm liên tiếp. Trong ARIMA, số lần sai phân cần thực hiện chính là tham số d .

Áp dụng cho tập huấn luyện:

$$y_{\text{train}} = [10, 12, 14, 15, 17, 19].$$

Ta có:

$$\Delta y_2 = 12 - 10 = 2,$$

$$\Delta y_3 = 14 - 12 = 2,$$

$$\Delta y_4 = 15 - 14 = 1,$$

$$\Delta y_5 = 17 - 15 = 2,$$

$$\Delta y_6 = 19 - 17 = 2.$$

Do đó, chuỗi sau sai phân là:

$$\Delta y = [2, 2, 1, 2, 2].$$

Thời điểm	2	3	4	5	6
Δy_t	2	2	1	2	2

Kiểm định ADF

Kiểm định Augmented Dickey-Fuller (ADF) là một kiểm định nghiệm đơn vị dùng để đánh giá chuỗi thời gian có dừng hay không. Trong quy trình ARIMA, ADF thường được dùng để hỗ trợ quyết định số lần sai phân, tức là lựa chọn tham số d .

Dạng tổng quát của kiểm định ADF là:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^k \phi_i \Delta y_{t-i} + \varepsilon_t.$$

Trong đó, giả thuyết kiểm định là:

$$\begin{cases} H_0 : \gamma = 0, & \text{chuỗi có nghiệm đơn vị, tức là không dừng,} \\ H_1 : \gamma < 0, & \text{chuỗi không có nghiệm đơn vị, tức là dừng.} \end{cases}$$

Nếu chọn mức ý nghĩa $\alpha = 0.05$, quy tắc đọc kết quả là:

$$p\text{-value} < 0.05 \Rightarrow \text{bác bỏ } H_0.$$

Khi đó, ta có bằng chứng thống kê để xem chuỗi là dừng ở mức ý nghĩa 5%.

Trong ví dụ minh họa này, ta không dùng ADF để kết luận chính thức. Lý do là ADF được ước lượng thông qua một mô hình hồi quy; với tập huấn luyện chỉ có 6 quan sát, sau sai phân bậc một chỉ còn 5 giá trị sai phân. Nếu mô hình ADF có hằng số và không dùng độ trễ bổ sung, số quan sát hiệu dụng chỉ khoảng 5, trong khi đã phải ước lượng ít nhất các tham số của phương trình kiểm định. Nếu thêm xu hướng t hoặc thêm các độ trễ Δy_{t-i} , bậc tự do còn lại sẽ giảm thêm.

Vì vậy, ADF trong phần này được trình bày như công cụ tổng quát cho dữ liệu thật. Với ví dụ nhỏ, ta dùng phép sai phân để minh họa trực tiếp cách lựa chọn d . Chuỗi gốc có xu hướng tăng, còn chuỗi sau sai phân:

$$\Delta y = [2, 2, 1, 2, 2]$$

dao động quanh một mức thay đổi ổn định hơn. Do đó, trong ví dụ minh họa, ta chọn:

$$d = 1.$$

III.2. Nhận diện p và q bằng ACF/PACF

Sau khi chọn $d = 1$, ta đặt:

$$x_t = \Delta y_t.$$

Khi đó, chuỗi cần phân tích là:

$$x = [2, 2, 1, 2, 2].$$

Công thức ACF đã được giới thiệu ở phần cơ sở lý thuyết:

$$r_k = \frac{\sum_{t=k+1}^T (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}.$$

Công thức này đo mức tương quan giữa giá trị hiện tại và giá trị quá khứ tại lag k . Trong quy trình ARIMA, ACF thường được dùng để gợi ý q , còn PACF thường được dùng để gợi ý p . Với chuỗi x , trung bình mẫu là:

$$\bar{x} = \frac{2 + 2 + 1 + 2 + 2}{5} = 1.8.$$

Độ lệch so với trung bình là:

$$x_t - \bar{x} = [0.2, 0.2, -0.8, 0.2, 0.2].$$

Với lag 1, ta có:

$$r_1 = \frac{(0.2)(0.2) + (-0.8)(0.2) + (0.2)(-0.8) + (0.2)(0.2)}{(0.2)^2 + (0.2)^2 + (-0.8)^2 + (0.2)^2 + (0.2)^2}.$$

Tử số là:

$$0.04 - 0.16 - 0.16 + 0.04 = -0.24.$$

Mẫu số là:

$$0.04 + 0.04 + 0.64 + 0.04 + 0.04 = 0.80.$$

Do đó:

$$r_1 = \frac{-0.24}{0.80} = -0.30.$$

Với lag 1, PACF bằng ACF:

$$PACF(1) = ACF(1) = -0.30.$$

Khoảng tin cậy trong ACF và PACF

Khi quan sát ACF/PACF, ta thường dùng khoảng tin cậy để đánh giá một lag có nổi bật hay không. Nếu chuỗi đang xét gần với nhiều trắng, sai số chuẩn xấp xỉ của hệ số tự tương quan mẫu là:

$$SE(r_k) \approx \frac{1}{\sqrt{T}}.$$

Với khoảng tin cậy hai phía mức 95%, ta dùng phân vị chuẩn:

$$z_{0.975} \approx 1.96.$$

Do đó, khoảng tin cậy xấp xỉ quanh 0 là:

$$\pm 1.96 \cdot SE(r_k) = \pm \frac{1.96}{\sqrt{T}}.$$

Số 1.96 xuất phát từ phân phối chuẩn chuẩn hóa $N(0, 1)$: khoảng $[-1.96, 1.96]$ chứa xấp xỉ 95% xác suất.

Trong ví dụ này, chuỗi sai phân có $T = 5$ quan sát, nên:

$$\pm \frac{1.96}{\sqrt{5}} \approx \pm 0.88.$$

Vì $r_1 = -0.30$ nằm trong khoảng $[-0.88, 0.88]$, lag 1 không được xem là nổi bật theo xấp xỉ này. Tuy nhiên, do $T = 5$ là rất nhỏ, kết luận này chỉ dùng để minh họa cách đọc ACF/PACF, không phải một kết luận thống kê mạnh.

Do đó, trong ví dụ minh họa, ta chọn mô hình đơn giản:

$$p = 0, \quad q = 0.$$

Kết hợp với $d = 1$, mô hình ứng viên là:

$$ARIMA(0, 1, 0).$$

III.3. Đặt mô hình ứng viên và ước lượng tham số**Tập mô hình ứng viên**

Trong dữ liệu thật, ACF/PACF thường không dùng để chốt duy nhất một mô hình. Thay vào đó, ta dùng chúng để giới hạn một tập mô hình ứng viên, sau đó so sánh các mô hình trong tập này bằng một tiêu chí như AIC.

Tập mô hình ứng viên có thể viết tổng quát là:

$$\mathcal{M} = \{ARIMA(p, d, q) \mid p \in P, q \in Q\}.$$

Nếu đã chọn $d = 1$, một không gian tìm kiếm thường gặp là:

$$\mathcal{M} = \{ARIMA(p, 1, q) \mid p, q \in \{0, 1, 2, 3, 4, 5\}\}.$$

Trong ví dụ nhỏ này, ACF/PACF không cho thấy lag nổi bật, nên ta xét trực tiếp mô hình:

$$ARIMA(0, 1, 0)$$

với một hằng số xu hướng trung bình, còn gọi là **drift**. Trong mô hình này, drift biểu diễn mức tăng hoặc giảm trung bình của chuỗi sau mỗi bước thời gian. Mô hình này được viết trên chuỗi sai phân như sau:

$$\Delta y_t = \mu + \varepsilon_t.$$

Tương đương với dạng trên chuỗi gốc:

$$y_t = y_{t-1} + \mu + \varepsilon_t.$$

Trong đó, μ là mức thay đổi trung bình sau mỗi bước thời gian, còn ε_t là sai số ngẫu nhiên tại thời điểm t .

Ta ước lượng μ bằng trung bình của chuỗi sai phân:

$$\hat{\mu} = \frac{1}{5} \sum_{t=2}^6 \Delta y_t.$$

Thay số:

$$\hat{\mu} = \frac{2 + 2 + 1 + 2 + 2}{5} = 1.8.$$

Vậy mô hình sau khi ước lượng là:

$$\Delta y_t = 1.8 + \varepsilon_t.$$

Hay tương đương:

$$y_t = y_{t-1} + 1.8 + \varepsilon_t.$$

III.4. Chọn mô hình bằng AIC

Tiêu chí AIC

AIC là tiêu chí dùng để so sánh nhiều mô hình ứng viên được huấn luyện trên cùng một tập dữ liệu. Tiêu chí này cân bằng giữa độ khớp dữ liệu và độ phức tạp của mô hình.

Công thức AIC là:

$$AIC = 2k - 2 \ln(\hat{L}).$$

Trong đó:

- k là số tham số được ước lượng trong mô hình.

- $\hat{L}$ là giá trị likelihood cực đại của mô hình.

Quy tắc chọn mô hình là:

$$\mathcal{M}^* = \arg \min_{\mathcal{M}_i} AIC(\mathcal{M}_i).$$

Nghĩa là mô hình có AIC nhỏ nhất trong tập ứng viên sẽ được ưu tiên lựa chọn.

Trong ví dụ nhỏ này, ta chỉ tính AIC cho mô hình minh họa $ARIMA(0, 1, 0)$ có drift. Phần dư trên chuỗi sai phân là:

$$\hat{\varepsilon}_t = \Delta y_t - \hat{\mu}.$$

Với $\hat{\mu} = 1.8$, ta có:

$$\hat{\varepsilon} = [2 - 1.8, 2 - 1.8, 1 - 1.8, 2 - 1.8, 2 - 1.8].$$

$$\hat{\varepsilon} = [0.2, 0.2, -0.8, 0.2, 0.2].$$

Tổng bình phương sai số là:

$$SSE = 0.2^2 + 0.2^2 + (-0.8)^2 + 0.2^2 + 0.2^2 = 0.8.$$

Phương sai nhiều ước lượng theo MLE là:

$$\hat{\sigma}^2 = \frac{SSE}{n} = \frac{0.8}{5} = 0.16.$$

Nếu giả sử phần dư tuân theo phân phối chuẩn, log-likelihood tại cực đại là:

$$\ln(\hat{L}) = -\frac{n}{2} [\ln(2\pi\hat{\sigma}^2) + 1].$$

Thay $n = 5$ và $\hat{\sigma}^2 = 0.16$:

$$\ln(\hat{L}) = -\frac{5}{2} [\ln(2\pi \cdot 0.16) + 1] \approx -2.513.$$

Với mô hình này, ta ước lượng hai tham số là drift μ và phương sai nhiều σ^2 , nên:

$$k = 2.$$

Do đó:

$$AIC = 2(2) - 2(-2.513) = 9.026.$$

Giá trị $AIC \approx 9.026$ ở đây chỉ minh họa cách tính cho một mô hình. Trong thực hành, AIC không được diễn giải như một thước đo tốt/xấu tuyệt đối. Nó chỉ có ý nghĩa tương đối khi so sánh nhiều mô hình ứng viên được huấn luyện trên cùng một tập dữ liệu.

III.5. Chẩn đoán phần dư

Sau khi ước lượng mô hình, ta kiểm tra phần dư để xem mô hình còn bỏ sót cấu trúc phụ thuộc nào trong dữ liệu hay không. Phần dư trên chuỗi sai phân được tính bởi:

$$\hat{\varepsilon}_t = \Delta y_t - \widehat{\Delta y}_t.$$

Với mô hình $ARIMA(0, 1, 0)$ có drift, ta có:

$$\widehat{\Delta y}_t = \hat{\mu} = 1.8.$$

Do đó:

$$\hat{\varepsilon} = [0.2, 0.2, -0.8, 0.2, 0.2].$$

Thời điểm	2	3	4	5	6
Δy_t	2	2	1	2	2
$\widehat{\Delta y}_t$	1.8	1.8	1.8	1.8	1.8
$\hat{\varepsilon}_t$	0.2	0.2	-0.8	0.2	0.2

Trung bình phần dư là:

$$\bar{\hat{\varepsilon}} = \frac{0.2 + 0.2 - 0.8 + 0.2 + 0.2}{5} = 0.$$

Kiểm định Ljung-Box

Kiểm định Ljung-Box được dùng để kiểm tra phần dư còn tự tương quan đáng kể hay không. Nếu phần dư vẫn còn tự tương quan, mô hình có thể chưa khai thác hết cấu trúc thời gian trong dữ liệu.

Công thức thống kê Ljung-Box là:

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}.$$

Trong đó:

- n là số quan sát của phần dư.
- h là số lag cần kiểm tra.
- $\hat{\rho}_k$ là tự tương quan mẫu của phần dư tại lag k .

Giả thuyết kiểm định là:

$$\begin{cases} H_0 : \text{phần dư không có tự tương quan đáng kể,} \\ H_1 : \text{phần dư còn tự tương quan đáng kể.} \end{cases}$$

Với ví dụ nhỏ, nếu xét $h = 1$ và $\hat{\rho}_1 \approx -0.30$, ta có:

$$Q = 5(5 + 2) \frac{(-0.30)^2}{5 - 1} = 35 \cdot \frac{0.09}{4} \approx 0.79.$$

Giá trị $Q \approx 0.79$ chỉ dùng để minh họa cách thay số vào công thức. Với $n = 5$, kiểm định Ljung-Box không nên được dùng để đưa ra kết luận mạnh, vì số lượng phần dư quá ít và p -value của kiểm định dựa trên xấp xỉ phân phối khi mẫu đủ lớn.

Trong thực hành, ta sẽ đọc p -value của kiểm định. Nếu p -value lớn hơn mức ý nghĩa đã chọn, ví dụ 0.05, ta chưa có bằng chứng để kết luận phần dư còn tự tương quan đáng kể.

III.6. Dự báo giá trị tương lai

Sau khi mô hình vượt qua bước chẩn đoán phần dư, ta dùng mô hình để dự báo các thời điểm tương lai. Với mô hình $ARIMA(0, 1, 0)$ có drift đã ước lượng:

$$y_t = y_{t-1} + \hat{\mu} + \varepsilon_t,$$

công thức dự báo h bước tiếp theo là:

$$\hat{y}_{T+h|T} = y_T + h\hat{\mu}.$$

Công thức này là công thức dự báo của mô hình minh họa $ARIMA(0, 1, 0)$ có drift, không phải công thức tổng quát cho mọi mô hình ARIMA. Nó cho biết dự báo tương lai được xây dựng từ giá trị cuối cùng đã quan sát y_T , cộng thêm mức thay đổi trung bình $\hat{\mu}$ qua từng bước dự báo. Trong ví dụ này:

$$T = 6, \quad y_6 = 19, \quad \hat{\mu} = 1.8.$$

Dự báo cho thời điểm 7:

$$\hat{y}_{7|6} = y_6 + 1 \cdot \hat{\mu} = 19 + 1.8 = 20.8.$$

Dự báo cho thời điểm 8:

$$\hat{y}_{8|6} = y_6 + 2 \cdot \hat{\mu} = 19 + 2(1.8) = 22.6.$$

Do đó, giá trị dự báo trên tập kiểm tra là:

$$\hat{y}_{\text{test}} = [20.8, 22.6].$$

Thời điểm	7	8
Giá trị thật y_t	20	22
Giá trị dự báo $\hat{y}_t$	20.8	22.6
Sai số $e_t = y_t - \hat{y}_t$	-0.8	-0.6

III.7. Đánh giá sai số dự báo

Các thước đo đánh giá dự báo

Sau khi có dự báo, ta cần so sánh giá trị dự báo $\hat{y}_t$ với giá trị thật y_t . MAE, RMSE và MAPE là ba thước đo phổ biến để lượng hóa mức sai số của mô hình.

Sai số dự báo tại mỗi thời điểm là:

$$e_t = y_t - \hat{y}_t.$$

Với hai điểm kiểm tra:

$$e_7 = 20 - 20.8 = -0.8,$$

$$e_8 = 22 - 22.6 = -0.6.$$

MAE đo sai số tuyệt đối trung bình:

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|.$$

Thay số:

$$MAE = \frac{|20 - 20.8| + |22 - 22.6|}{2} = \frac{0.8 + 0.6}{2} = 0.7.$$

RMSE phạt mạnh hơn các sai số lớn:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}.$$

Thay số:

$$RMSE = \sqrt{\frac{(-0.8)^2 + (-0.6)^2}{2}} = \sqrt{\frac{0.64 + 0.36}{2}} = \sqrt{0.5} \approx 0.707.$$

MAPE biểu diễn sai số theo phần trăm:

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|.$$

Thay số:

$$MAPE = \frac{100}{2} \left(\frac{0.8}{20} + \frac{0.6}{22} \right).$$

$$MAPE = 50(0.04 + 0.0273) = 3.36\%.$$

Với MAPE, cần cẩn thận khi giá trị thật y_t gần 0, vì mẫu số nhỏ có thể làm MAPE tăng rất lớn. Trong ví dụ này, các giá trị thật là 20 và 22, nên MAPE vẫn dễ diễn giải.

Thước đo	Giá trị
MAE	0.7
RMSE	0.707
MAPE	3.36%

III.8. Giới hạn của ARIMA và hướng mở rộng

Với ARIMA thuần, sau khi sai phân d lần, ta đặt:

$$x_t = \Delta^d y_t.$$

Khi đó, mô hình ARIMA có thể viết dưới dạng:

$$x_t = c + \phi_1 x_{t-1} + \dots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

Từ công thức trên, ta thấy mô hình chỉ sử dụng hai nhóm thông tin: các giá trị quá khứ của chính chuỗi x_t và các sai số quá khứ ε_t . Vì vậy, ARIMA thuần phù hợp với bài toán chuỗi thời gian đơn biến, khi giá trị tương lai chủ yếu được giải thích bởi lịch sử của chính chuỗi đó.

Tuy nhiên, trong nhiều bài toán thực tế, giá trị cần dự báo còn chịu ảnh hưởng bởi các biến bên ngoài như ngày lễ, thời tiết, giá bán, chương trình khuyến mãi, lưu lượng truy cập hoặc các yếu tố kinh tế. Những biến này không xuất hiện trong công thức ARIMA thuần, nên mô hình không trực tiếp khai thác được các nguồn thông tin đó.

Khi bài toán có thêm biến ngoại sinh $z_{1,t}, z_{2,t}, \dots, z_{m,t}$, ta có thể mở rộng sang mô hình hồi quy với sai số ARIMA:

$$y_t = \beta_0 + \beta_1 z_{1,t} + \beta_2 z_{2,t} + \dots + \beta_m z_{m,t} + \eta_t,$$

trong đó η_t là phần sai số được mô hình hóa bằng ARIMA. Đây là ý tưởng của các mô hình mở rộng như ARIMAX hoặc SARIMAX. Nếu dữ liệu có thêm yếu tố mùa vụ, SARIMAX thường được dùng vì có thể kết hợp cả thành phần mùa vụ và biến ngoại sinh.

Một hướng mở rộng khác là chuyển bài toán chuỗi thời gian sang dạng học có giám sát. Khi đó, giá trị cần dự báo y_t được học từ các đặc trưng được tạo ra từ dữ liệu quá khứ và các biến bên ngoài:

$$y_t = f(y_{t-1}, y_{t-2}, \dots, \text{lag features}, \text{rolling features}, \text{calendar features}, \text{exogenous variables}).$$

Với cách tiếp cận này, các mô hình như XGBoost hoặc LightGBM có thể học quan hệ phi tuyến và kết hợp nhiều biến đầu vào. Đây không còn là ARIMA thuần, mà là hướng *machine learning for time series forecasting*.

Để kiểm chứng điều này, chúng ta cùng đến với một ví dụ xây dựng mô hình ARIMA cho tập dữ liệu Sunspots bằng Python và so sánh với mô hình XGBoost.

IV. Ví dụ minh họa với Python

Trong phần này, ta triển khai quy trình xây dựng mô hình ARIMA theo phương pháp Box–Jenkins bằng Python trên bộ dữ liệu *Sunspots*. Quy trình gồm các bước: chuẩn bị dữ liệu, kiểm tra tính dừng, lựa chọn mô hình, huấn luyện mô hình, chẩn đoán phần dư và dự báo trên tập kiểm tra.

IV.1. Cài đặt và import thư viện

Trước hết, ta cài đặt và import các thư viện cần thiết cho việc xử lý dữ liệu, trực quan hóa, kiểm định thống kê và xây dựng mô hình ARIMA.

Cài đặt thư viện

```
1 !pip install pmdarima
```

Import các thư viện cần thiết

```
1 import warnings
2
3 import matplotlib.pyplot as plt
4 import numpy as np
5 import pandas as pd
6 import statsmodels.api as sm
7
8 from pmdarima import auto_arima
9 from sklearn.metrics import mean_absolute_error, mean_squared_error
10 from statsmodels.stats.diagnostic import acorr_ljungbox
11 from statsmodels.tsa.arima.model import ARIMA
12 from statsmodels.tsa.stattools import adfuller
13
14 warnings.filterwarnings("ignore")
```

IV.2. Chuẩn bị và trực quan hóa dữ liệu


Trước hết, ta nạp bộ dữ liệu *Sunspots*, chuyển dữ liệu về dạng chuỗi thời gian và chia thành tập huấn luyện và tập kiểm tra. Trong ví dụ này, 20 năm cuối được dùng làm tập kiểm tra.

Chuẩn bị và chia dữ liệu

```

1 data = sm.datasets.sunspots.load_pandas().data
2
3 TEST_SIZE = 20
4 series = pd.Series(
5     data["SUNACTIVITY"].values,
6     index=pd.period_range("1700", periods=len(data), freq="Y").to_timestamp(),
7     name="sunspots"
8 )
9
10 train = series.iloc[:-TEST_SIZE]
11 test = series.iloc[-TEST_SIZE:]
12
13 print(series.head().to_string())
14 print(f"Train: {train.index[0].year}-{train.index[-1].year} ({len(train)} observations)
15       ")
16 print(f"Test: {test.index[0].year}-{test.index[-1].year} ({len(test)} observations)")

```



Hình 10: Chuỗi số vết đen mặt trời trên tập huấn luyện

Hình 10 cho thấy chuỗi *Sunspots* có dao động chu kỳ rõ rệt và biên độ thay đổi qua các giai đoạn. Vì vậy, trước khi xây dựng mô hình ARIMA, ta cần kiểm tra tính dừng của chuỗi trên tập huấn luyện ở bước tiếp theo.

IV.3. Kiểm tra tính dừng và chọn d

Ta sử dụng kiểm định ADF để kiểm tra tính dừng của chuỗi gốc và chuỗi sai phân bậc một. Nếu chuỗi gốc chưa dừng nhưng chuỗi sai phân đã dừng, ta chọn $d = 1$.


Kiểm tra tính dừng bằng ADF

```
1 raw_adf_stat, raw_p_value, *_ = adfuller(train)
2
3 diff_train = train.diff().dropna()
4 diff_adf_stat, diff_p_value, *_ = adfuller(diff_train)
5
6 print(f"ADF statistic train series: {raw_adf_stat:.4f}")
7 print(f"ADF p-value train series: {raw_p_value:.4f}")
8 print(f"ADF statistic first difference: {diff_adf_stat:.4f}")
9 print(f"ADF p-value first difference: {diff_p_value:.4e}")
```

Output

```
1 ADF statistic train series: -2.3852
2 ADF p-value train series: 0.1459
3 ADF statistic first difference: -14.0741
4 ADF p-value first difference: 2.9050e-26
```

Kết quả cho thấy p -value của chuỗi gốc bằng 0.1459, lớn hơn 0.05, nên ta chưa có đủ bằng chứng để xem chuỗi gốc là dừng. Sau khi sai phân bậc một, p -value giảm xuống 2.9050×10^{-26} , nhỏ hơn rất nhiều so với 0.05. Vì vậy, ta chọn $d = 1$ cho mô hình ARIMA.



Hình 11: Minh họa tác động của sai phân bậc một đối với chuỗi Sunspots trên tập huấn luyện

Hình 11 cho thấy sau khi sai phân bậc một, chuỗi dao động quanh mức 0 rõ hơn. Kết quả này phù hợp với kiểm định ADF và hỗ trợ lựa chọn $d = 1$.

IV.4. Nhận diện p, q bằng ACF/PACF



Sau khi chọn $d = 1$, ta quan sát ACF và PACF của chuỗi sai phân để xác định miền giá trị hợp lý cho p và q .

Vẽ đồ thị ACF & PACF

```

1 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
2
3 # Sau khi đã chọn d=1, ACF/PACF cần được quan sát trên chuỗi sai phân.
4 acf_input = diff_train
5
6 fig, axes = plt.subplots(1, 2, figsize=(11.0, 4.4))
7
8 plot_acf(
9     acf_input,
10    ax=axes[0],
11    lags=12,
12    zero=False,
13    color="#344f1e",
14    title="ACF - Auto-Correlation Function"
15 )
16
17 plot_pacf(
18     acf_input,
19     ax=axes[1],
20     lags=12,
21     zero=False,
22     color="#344f1e",
23     method="yw",
24     title="PACF - Partial Auto-Correlation Function"
25 )
26
27 for ax in axes:
28     ax.set_xlabel("Độ trễ (năm)")
29     ax.set_ylabel("Tương quan")
30     ax.grid(alpha=0.25)
31
32 fig.tight_layout(pad=1.0)
33 plt.show()

```



Hình 12: ACF và PACF của chuỗi Sunspots sau khi sai phân bậc một

Từ Hình 12, chuỗi sai phân vẫn còn tự tương quan ở một số độ trễ. Vì ACF/PACF không đưa ra một lựa chọn duy nhất, ta dùng chúng để xác định miền tìm kiếm ban đầu và xét $p, q \in \{0, 1, 2, 3, 4, 5\}$. Khi đó, không gian mô hình ứng viên là:

$$\mathcal{M} = \{\text{ARIMA}(p, 1, q) \mid p, q \in \{0, 1, 2, 3, 4, 5\}\}. \quad (8)$$

IV.5. Lựa chọn mô hình bằng AIC

Với không gian tìm kiếm ở (8), ta sử dụng `auto_arima` để ước lượng các mô hình ứng viên và chọn mô hình có AIC nhỏ nhất.

Tự động chọn p và q bằng auto_arima


```

1 auto_model_aic = auto_arima(
2     train,
3     start_p=0,
4     start_q=0,
5     max_p=5,
6     max_q=5,
7     d=1,
8     seasonal=False,
9     information_criterion="aic",
10    trace=False,
11    error_action="ignore",
12    suppress_warnings=True,
13    stepwise=False,
14    max_order=None,
15    with_intercept=False
16 )
17
18 selected_order = auto_model_aic.order
19
20 print("Best order by AIC:", selected_order)
```

Output

```
1 Best order by AIC: (5, 1, 5)
```

Trong đoạn mã trên, `stepwise=False` và `max_order=None` giúp thuật toán xét toàn bộ các tổ hợp (p, q) trong miền tìm kiếm. Kết quả có thể được biểu diễn dưới dạng lưới AIC.



Hình 13: Lưới giá trị AIC của các mô hình ARIMA($p, 1, q$). Ô khoanh đỏ đánh dấu mô hình có AIC thấp nhất

Hình 13 cho thấy mô hình có AIC thấp nhất là ARIMA(5, 1, 5). Mô hình này được chọn để huấn luyện và kiểm tra phần dư ở bước tiếp theo.

IV.6. Huấn luyện mô hình ARIMA được chọn

Sau khi chọn được cấu hình ARIMA(5, 1, 5), ta ước lượng mô hình cuối cùng trên toàn bộ tập huấn luyện bằng `statsmodels`.

Huấn luyện mô hình ARIMA được chọn

```

1 final_model = ARIMA(train, order=selected_order, trend="n")
2 final_result = final_model.fit()
3
4 print("Selected ARIMA order:", selected_order)
5 print(final_result.summary())

```

Mô hình sau khi được fit sẽ được dùng để lấy phần dư và thực hiện chẩn đoán trước khi dự báo.

IV.7. Chẩn đoán phần dư

Ta kiểm tra phần dư của mô hình bằng ACF phần dư và kiểm định Ljung–Box. Nếu phần dư không còn tự tương quan đáng kể, mô hình có thể được sử dụng cho bước dự báo.

Chẩn đoán phần dư bằng kiểm định Ljung–Box

```

1 from statsmodels.stats.diagnostic import acorr_ljungbox
2
3 residuals = final_result.resid.dropna()
4 model_df = selected_order[0] + selected_order[2]
5
6 ljung_box_result = acorr_ljungbox(
7     residuals,
8     lags=[15, 20, 30],
9     model_df=model_df,
10    return_df=True
11 )
12
13 print("Selected ARIMA order:", selected_order)
14 print("Model df:", model_df)
15 print(ljung_box_result)


```

Output

```

1 Selected ARIMA order: (5, 1, 5)
2 Model df: 10
3      lb_stat  lb_pvalue
4 15    7.810433  0.166997
5 20   11.686933  0.306555
6 30   26.035866  0.164631

```



Hình 14: Minh họa chẩn đoán phần dư của mô hình ARIMA được chọn trên tập huấn luyện thông qua chuỗi phần dư, ACF phần dư và kiểm định Ljung–Box

Hình 14 cho thấy phần dư dao động quanh 0, ACF phần dư hầu hết nằm trong khoảng tin cậy, và p -value Ljung–Box đều lớn hơn 0.05. Do đó, phần dư có thể được xem là gần với nhiễu trắng.

IV.8. Dự báo trên tập kiểm tra và so sánh mô hình

Sau khi mô hình đạt yêu cầu ở bước chẩn đoán phần dư, ta sử dụng ARIMA(5, 1, 5) để dự báo trên tập kiểm tra và tính các thước đo sai số.


Dự báo trên tập kiểm tra và đánh giá sai số

```
1 n_steps = len(test)
2
3 forecast_result = final_result.get_forecast(steps=n_steps)
4
5 forecast = forecast_result.predicted_mean
6 conf_int = forecast_result.conf_int()
7
8 forecast.index = test.index
9 conf_int.index = test.index
10
11 mae = mean_absolute_error(test, forecast)
12 rmse = np.sqrt(mean_squared_error(test, forecast))
13
14 # MAPE an toàn hơn khi dữ liệu có thể chứa giá trị bằng 0.
15 nonzero_mask = test != 0
16 mape = np.mean(
17     np.abs((test[nonzero_mask] - forecast[nonzero_mask]) / test[nonzero_mask])
18 ) * 100
19
20 print(f"MAE: {mae:.4f}")
21 print(f"RMSE: {rmse:.4f}")
22 print(f"MAPE: {mape:.2f}%")
```

Output

```
1 MAE: 27.6419
2 RMSE: 30.9555
3 MAPE: 210.98%
```

MAE và RMSE cho biết mức sai số tuyệt đối trung bình của mô hình trên tập kiểm tra. MAPE khá lớn vì dữ liệu *Sunspots* có một số giá trị thực tế nhỏ, làm sai số tương đối bị phóng đại.



Hình 15: Kết quả dự báo của mô hình ARIMA(5, 1, 5) trên tập kiểm tra

Hình 15 cho thấy ARIMA phần nào bắt được xu hướng dao động tổng quát, nhưng sai số vẫn còn lớn và mô hình chưa bám tốt các điểm đảo chiều mạnh của chuỗi.


Để minh họa hướng mở rộng từ ARIMA sang học máy, ta so sánh ARIMA(5, 1, 5) với mô hình XGBoost. Khác với ARIMA thuần, XGBoost được huấn luyện từ các đặc trưng được tạo thêm từ chuỗi thời gian như *lag features*, *rolling features* và đặc trưng chu kỳ.

So sánh ARIMA với XGBoost

```
1 comparison_df = pd.DataFrame([
2     metrics(test, arima_forecast, f"ARIMA{selected_order}"),
3     metrics(test, xgb_forecast, "XGBoost + features")
4 ]).sort_values("RMSE").reset_index(drop=True)
5
6 display(comparison_df)
```

Output

Model	MAE	RMSE	MAPE (%)	WAPE (%)
XGBoost + features	19.3621	21.5127	129.3898	29.2479
ARIMA(5, 1, 5)	27.6419	30.9555	210.9775	41.7551



Hình 16: So sánh kết quả dự báo giữa ARIMA và XGBoost trên tập kiểm tra

Kết quả so sánh cho thấy XGBoost đạt sai số thấp hơn ARIMA trên tập kiểm tra. Cụ thể, XGBoost có $MAE = 19.36$, $RMSE = 21.51$, $MAPE = 129.39\%$ và $WAPE = 29.25\%$, trong khi ARIMA có $MAE = 27.64$, $RMSE = 30.96$, $MAPE = 210.98\%$ và $WAPE = 41.76\%$.

Kết quả này minh họa một giới hạn quan trọng của ARIMA thuần: mô hình chỉ sử dụng giá trị quá khứ và sai số quá khứ của chính chuỗi thời gian. Trong khi đó, XGBoost có thể khai thác thêm các đặc trưng được thiết kế từ dữ liệu như lag, thống kê trượt và đặc trưng chu kỳ.

Do đó, ARIMA vẫn là một mô hình nền tảng quan trọng cho dự báo chuỗi thời gian đơn biến. Tuy nhiên, với các bài toán có cấu trúc phi tuyến, chu kỳ mạnh hoặc có thêm biến ngoại sinh, các mô hình học máy như XGBoost hoặc LightGBM có thể là hướng mở rộng phù hợp.



Các bạn có thể xem nội các đoạn code phần minh họa bằng python ở đây

[Notebook đáp án](#)

V. Thực hành ARIMA trên Web Demo

Sau khi nắm được cơ sở lý thuyết và quy trình ARIMA, người học có thể thực hành trực tiếp trên giao diện [ARIMA Demo Lab](#). Ứng dụng cho phép đi lần lượt qua các bước: chọn dữ liệu, quan sát chuỗi, sai phân, xem ACF/PACF, fit mô hình và đánh giá dự báo.

Chọn dữ liệu đầu vào.

Người dùng có thể chọn dataset mẫu hoặc tải lên file CSV gồm cột thời gian và cột giá trị số để bắt đầu phân tích chuỗi thời gian.

1. Chọn dữ liệu

Bạn có thể dùng sample dataset đi kèm để demo nhanh, hoặc tải lên CSV riêng.

Nguồn dữ liệu

☒ Dùng sample dataset ☐ Tải lên CSV riêng


Đang dùng dữ liệu: `sample_series.csv`

Hình 17: Giao diện chọn dataset mẫu hoặc tải lên file CSV

Quan sát chuỗi gốc.

Người dùng quan sát chuỗi gốc để nhận diện xu hướng, mùa vụ và biến động bất thường.

Chuỗi thời gian gốc



Hình 18: Giao diện quan sát chuỗi thời gian gốc

Sai phân và kiểm tra tính dừng.

Người dùng thử các bậc sai phân và dùng ADF để hỗ trợ đánh giá tính dừng của chuỗi.

3. Differencing ⇌

$d = 0$: chưa sai phân. $d = 1$: sai phân bậc 1. $d = 2$: sai phân bậc 2.

Gợi ý d

Gợi ý d: 1. Bạn có thể chỉnh tay ở mục chọn d ngay bên dưới.

	d	adf_stat	adf_pvalue	kpss_stat	kpss_pvalue	decision
0	0	0.0903	0.9654	0.714	0.0123	Chưa đủ tín hiệu dừng
1	1	-5.209	0.000008	0.2059	0.1	Gợi ý dừng

Mức sai phân để quan sát

☐ $d = 0$: chưa sai phân ☒ $d = 1$: sai phân bậc 1 ☐ $d = 2$: sai phân bậc 2

Hình 19: Giao diện quan sát chuỗi thời gian gốc

Hình 19 giúp so sánh chuỗi gốc và chuỗi sau sai phân để chọn d .

Quan sát ACF và PACF.

Người dùng xem ACF/PACF trên chuỗi đã xử lý để lấy gợi ý ban đầu cho p và q .


4. ACF/PACF ⇌

Nên đọc ACF/PACF trên chuỗi đã được làm dừng. PACF thường gợi ý p ban đầu, còn ACF thường gợi ý q ban đầu.


Chọn số lag



ACF



PACF



Hình 20: Giao diện quan sát ACF và PACF

Chọn tham số và huấn luyện ARIMA.

Người dùng chọn p, d, q , fit mô hình ARIMA và xem các thông tin ước lượng như AIC/BIC.

p Số điểm test

1 - + 5

d Số bước forecast tương lai

1 - + 5 - +

q

1 - +

Mô hình đang chuẩn bị fit: **ARIMA(1,1,1)**

Chạy ARIMA

Hình 21: Giao diện chọn p, d, q và huấn luyện mô hình ARIMA

Xem dự báo, phần dư và thước đo đánh giá.

Người dùng xem forecast, residual và các chỉ số MAE, RMSE, MAPE trên cùng một trang.

Forecast tương lai ⇄

	date	forecast	lower_ci	upper_ci
0	2025-01-01 00:00:00	183.5198	179.6621	187.3775
1	2025-02-01 00:00:00	187.0396	181.4728	192.6064
2	2025-03-01 00:00:00	190.5594	183.6079	197.5109
3	2025-04-01 00:00:00	194.0792	185.9009	202.2575
4	2025-05-01 00:00:00	197.599	188.2892	206.9088

Hình 22: Giao diện xem bảng dự báo tương lai và khoảng tin cậy sau khi huấn luyện mô hình

Hình 22 tổng hợp kết quả dự báo, phần dư và các thước đo sai số để đánh giá mô hình.

Tóm lại, web demo giúp người học thực hành trọn quy trình ARIMA từ chọn dữ liệu đến đánh giá dự báo.

Tài liệu tham khảo

- [1] George E. P. Box et al. *Time Series Analysis: Forecasting and Control*. 5th ed. Hoboken, NJ: Wiley, 2015.
- [2] James D. Hamilton. *Time Series Analysis*. Princeton, NJ: Princeton University Press, 1994.
- [3] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. 3rd ed. OTexts, 2021. URL: <https://otexts.com/fpp3/>.
- [4] Penn State Department of Statistics. *STAT 510: Applied Time Series Analysis*. Online course material. 2026. URL: <https://online.stat.psu.edu/stat510/>.

Code & Demo

Các bạn có thể truy cập các đoạn code minh họa, link github và Web demo thực hành theo các liên kết dưới đây

- Notebook Colab minh họa: [Link Notebook](#)
- GitHub repository: [Link GitHub](#)
- Web demo thực hành: [Link Web](#)